Assignment 2. Data Preparation & Baseline — краткий исследовательский отчёт

Проект **lawrag**: офлайн-система вопросно-ответного поиска по кодексам Республики Казахстан (RU + KK). Ноутбук: `notebooks/assignment2/assignment2_data_preparation.ipynb` (воспроизводится через Restart → Run All).

---

1. Проблема

Специалист без юридического образования формулирует вопрос своими словами, нередко на казахском языке, а правильным ответом является конкретная статья кодекса в редакции на нужную дату [1]. Цель этапа — подготовить чистый и воспроизводимый набор данных «запрос → статья» без утечки между выборками и измерить на нём лексический baseline, который станет точкой отсчёта для плотного и гибридного поиска. Исследовательские вопросы: **RQ1** — какую долю запросов находит лексический поиск и как это зависит от типа запроса; **RQ2** — отличается ли казахская часть корпуса от русской по структуре и лексической находимости; **RQ3** — насколько корпус неоднороден во времени. Гипотезы: **H1** — TF-IDF хорош на заголовках (recall@10 > 0,8), но слаб на запросах-перефразах (< 0,5) и не работает межъязыково (< 0,1); **H2** — на казахских запросах baseline хуже, чем на русских; **H3** — более половины статей имеют редакцию новее даты принятия кодекса.

2. Данные

Первоисточник — Эталонный контрольный банк НПА РК *adilet.zan.kz* [2]. Снимок от 08.09.2026: 41 HTML-документ (85 МБ), 21 кодекс, тексты на русском и казахском (ГПК — только на русском). Документы разобраны парсером проекта в три таблицы: **articles** — 17 029 статей (8 771 уникальная статья × язык), ≈ 14,6 млн токенов; **chunks** — 43 857 индексируемых фрагментов (статья целиком или пункт большой статьи); **pairs** — 83 265 пар «запрос → статья», добытых из самого корпуса четырьмя способами: заголовок статьи, предложение со ссылкой на статью с вырезанным номером (xref), термин из статьи определений, межъязыковая пара RU↔KK. Размеченного набора запросов для казахстанского права не существует, поэтому сигнал извлекается из корпуса.

3. Методика

- **Качество данных** оценено количественно: 374 статьи (2,2 %) с пустым текстом, 495 русских статей без казахской версии (490 из них — ГПК), 152 статьи-заглушки «утратила силу», 9 181 полный дубликат пар (11 %), 2 347 запросов с несколькими целевыми статьями (7 088 пар, 8,5 %), 183 xref-запроса с оставшимся номером целевой статьи и 457 xref-запросов, являющихся редакционными пометками сайта, а не текстом нормы.
- **Очистка** (каждый шаг с обоснованием и состоянием до/после): приведение дат к `datetime64` с заменой служебных значений (1900-01-01, 9999-12-31) на `NaT` и флаг `is_current`; исключение заглушек из анализа длины; удаление дубликатов, неоднозначных запросов, утечек номера и редакционных пометок; ограничение межъязыковых пар и пар-заголовков до 8 000 каждых для баланса типов. Итог — 30 157 пар.
- **Признаки и target.** X — текст запроса и его язык; y — пара (статья, язык ответа). Уровень статьи выбран, потому что именно на неё ссылается юрист и именно её проверяет верификатор цитат; язык включён в target, иначе межъязыковая пара тривиально находила бы собственную статью. Тип пары используется только для анализа.
- **Разбиение** 80/10/10 через `StratifiedGroupKFold` [3]: группа — статья (общий идентификатор для RU и KK), страта — тип пары. Пересечение статей между выборками равно нулю, что исключает утечку через одну и ту же норму [4]. Получено 23 842 / 3 069 / 3 246 пар (6 005 / 740 / 740 статей). Данные — один снимок, а не временной ряд, поэтому перемешивание допустимо.
- **Baseline** — TF-IDF [5] по всем 43 857 фрагментам, ранжирование по косинусу; метрики recall@1, recall@10, MRR@10. Конфигурация выбрана на validation (словные 1–2-граммы, MRR@10 = 0,252, против символьных 3–5-грамм, 0,231), на test — однократная оценка.

4. Основные результаты

Test, TF-IDF (word 1–2)	n	recall@1	recall@10	MRR@10
все запросы	3 246	0,17	0,42	0,24
заголовок статьи	800	0,65	0,93	0,75
предложение с вырезанной ссылкой (xref)	1 116	0,02	0,40	0,13
термин (определение)	530	0,02	0,30	0,08
межъязыковой запрос	800	0,00	0,01	0,00
русские / казахские запросы	1 583 / 1 663	0,17 / 0,17	0,41 / 0,42	0,24 / 0,24

- **RQ1 (H1 подтверждена).** Лексический поиск надёжен только для буквальных фрагментов статьи (заголовки). На xref-запросах, ближайших к реальным вопросам, правильная статья попадает в топ-10 в 40 % случаев и почти никогда не стоит первой; средняя доля слов запроса, найденных в целевой статье, здесь лишь 0,31–0,33. Определения находятся плохо, хотя их слова есть в статье: термин встречается во многих статьях, и TF-IDF не отличает определяющую статью от использующих. Межъязыковой поиск лексическим методом невозможен (перекрытие ≈ 0,01).
- **RQ2 (H2 не подтверждена).** Казахская часть структурно полноценна: длины RU- и KK-версий одной статьи пропорциональны (медиана KK/RU = 0,98, корреляция лог-длин 0,997), что подтверждает выравнивание по идентификатору статьи. Метрики на русских и казахских запросах совпадают: в корпусных запросах словоформы те же, что в статье, поэтому отсутствие казахского стеммера не проявляется.
- **RQ3 (H3 подтверждена).** У 54 % статей текущая редакция новее даты принятия кодекса, у 33 % вступила в силу за последние три года; пики совпадают с принятием новых кодексов (2014, 2017, 2025). Дата «по состоянию на» должна оставаться жёстким фильтром поиска.
- Дополнительно: четверть статей (25,2 %) длиннее порога нарезки и даёт 71 % фрагментов индекса; корпус несбалансирован по кодексам (пять крупнейших — 47 % статей); хотя бы раз цитируются 38 % статей.

5. Ограничения

Запросы синтетические, получены из самого корпуса; реальные вопросы длиннее и разговорнее, а набор вопросов, выверенный юристом, ещё не составлен. Снимок содержит только текущие редакции. Число токенов оценено приближённо (≈ 2,5 символа на токен). Baseline покрывает лишь лексическую ветку поиска, без плотного поиска, слияния рангов и порога релевантности. Объяснение низкого recall@1 на xref-запросах (цитирующая статья сама попадает в выдачу) является гипотезой и отдельно не проверено. Условия повторного распространения текстов adilet требуют уточнения.

6. Выводы

Подготовлен воспроизводимый набор из 30 157 пар «запрос → статья» с разбиением по статьям без утечки. Лексический baseline (recall@10 = 0,42, MRR@10 = 0,24) задаёт нижнюю границу, а разбивка по типам показывает, где нужна следующая модель: на перефразированных и межъязыковых запросах. Это обосновывает доменное дообучение многоязычного эмбеддера [6] на train-части пар. Его успех следует оценивать именно на этих типах запросов, а не по средней метрике. Проверка H2 переносится на ручной набор вопросов: синтетические пары не способны измерить морфологическую проблему казахского языка.

Источники

1. Assignment 1. Project Proposal: lawrag — система вопросно-ответного поиска по кодексам Республики Казахстан, 2026.
2. Эталонный контрольный банк нормативных правовых актов Республики Казахстан «Әділет». URL: https://adilet.zan.kz (дата обращения: 08.09.2026).
3. Pedregosa F. et al. Scikit-learn: Machine Learning in Python // Journal of Machine Learning Research. 2011. Vol. 12. P. 2825–2830.
4. Kaufman S., Rosset S., Perlich C., Stitelman O. Leakage in data mining: Formulation, detection, and avoidance // ACM Transactions on Knowledge Discovery from Data. 2012. Vol. 6, No. 4.
5. Salton G., Buckley C. Term-weighting approaches in automatic text retrieval // Information Processing & Management. 1988. Vol. 24, No. 5. P. 513–523.
6. Chen J. et al. BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. arXiv:2402.03216, 2024.